Detección de Intrusiones en Redes IoT: Machine Learning frente a Ataques Minoritarios en RT-IoT2022

Porras Hurtado, Raúl[1], Pando Cabezas, Nicole Rashel[2], Delgado Santana, Francisco Luis[3]

[1]Universidad del Pacífico, Lima, Perú, RP.PorrasH@alum.up.edu.pe; [2]Universidad del Pacífico, Lima, Perú, NR.PandoC@alum.up.edu.pe; [3]Universidad del Pacífico, Lima, Perú, fl.delgadosa@alum.up.edu.pe
Docente: Ayma Quirita, Victor Hugo vh.aymaq@up.edu.pe

Resumen – Los hogares conectan a la red local dispositivos IoT como el LED de ThingSpeak, la bombilla Wipro y el sensor de temperatura por MQTT. Su tráfico pasa por el router y queda en registros etiquetados, que sirven para detectar intrusiones. El problema es el desbalance entre tipos de ataque: la denegación de servicio por solicitudes SYN concentra la mayor parte de los registros, y la fuerza bruta contra SSH y el escaneo FIN casi no aparecen. Exactitudes superiores al 99 % en conjuntos de IoT con clases desbalanceadas pueden ocultar el bajo desempeño en esas clases escasas (Reddy & Kumar, 2026). El objetivo es comparar K vecinos más cercanos, árbol de decisión, bosque aleatorio y red neuronal sobre RT-IoT2022, para determinar cuál reconoce los ataques con pocos registros en esa red doméstica. El método tentativo los mide con el recall de cada tipo, el macro-F1 y la matriz de confusión, y contrasta esas medidas con la exactitud global.

Palabras clave – detección de intrusiones; IoT doméstico; desbalance de clases; RT-IoT2022; macro-F1

INTRODUCCIÓN

I. Contextualización

El internet de las cosas (IoT) conecta objetos cotidianos e industriales a una red. Todo dispositivo, además de sensores o actuadores, tiene al menos una interfaz (Wi-Fi, Ethernet o Bluetooth) para comunicarse con el mundo digital (Fagan et al., 2022). El IoT llegó a la manufactura, la salud, el transporte y el hogar (Chui et al., 2021). En el hogar hay sensores y focos, como un LED, una bombilla y un sensor de temperatura, que antes no se conectaban, a diferencia de laptops o computadoras. A finales de 2025 había unos 22,3 mil millones de conexiones IoT en el mundo, y se espera que lleguen a 47,1 mil millones en 2031 (Ericsson, 2026).

Por lo general, estos dispositivos no salen directo a internet: usan un router. Ese espacio es la red local (LAN), compartida con computadoras y teléfonos, y el router es el puente con el exterior. Para ver un video de YouTube, la petición va al router, este la envía a los servidores y la respuesta vuelve por el mismo camino. Las redes de área amplia (WAN) y de área metropolitana (MAN) cubren un área mayor; este trabajo se centra en una red local pequeña, la de un hogar.

La información viaja en paquetes, con el mensaje y datos de control: dirección de origen, dirección de destino, protocolo y puerto de destino. El tráfico es la circulación de esos paquetes. Los protocolos son las reglas para comunicarse. TCP (protocolo de control de transmisión) abre una conexión y verifica que los datos lleguen completos y en orden; UDP (protocolo de datagramas de usuario) envía sin conexión ni garantía, a cambio de rapidez. El puerto indica el servicio: la dirección IP (protocolo de internet) identifica al equipo como la dirección identifica un edificio, y el puerto identifica al servicio como el número identifica un departamento. DNS (sistema de nombres de dominio) traduce nombres en direcciones; HTTP (protocolo de transferencia de hipertexto) pide páginas web; SSH (*Secure Shell*) permite el acceso remoto; MQTT (*Message Queuing Telemetry Transport*), de publicación y suscripción, sirve a dispositivos IoT con pocos recursos.

TCP abre esa conexión con *flags*, como una llamada. Quien llama envía SYN, el "aló"; el otro responde con SYN y ACK; el primero manda otro ACK y empiezan a intercambiar información. Al acabar, uno envía FIN. Si hay rechazo o error, RST corta de inmediato. Así se sabe si la comunicación empieza, sigue o terminó.

Los paquetes de una misma comunicación son un flujo. En el router se registra un resumen, no el contenido: cuántos paquetes envió cada uno, de qué tamaño, cuánto duró y qué señales aparecieron. Cada resumen es un registro; con una etiqueta de tráfico normal o de ataque, esos registros son los datos del modelo.

Ese tráfico muestra lo habitual y lo anómalo de un ataque. En el IoT la protección pesa más por el diseño de los aparatos. OWASP señala contraseñas débiles o de fábrica, servicios de red inseguros, falta de actualización y configuraciones inseguras activadas por defecto (OWASP Foundation, 2018). En 1,2 millones de dispositivos IoT de empresas y organizaciones de salud de Estados Unidos, el 98 % del tráfico iba sin cifrar y el 57 % de los dispositivos era vulnerable a ataques de severidad media o alta (Palo Alto Networks, 2020).

Cuatro ataques alteran el tráfico de distinta forma. El escaneo busca dispositivos conectados y puertos abiertos, y se ve como conversaciones muy cortas hacia distintos puertos; el escaneo FIN usa la señal FIN. La fuerza bruta prueba contraseñas y deja intentos repetidos hacia un mismo servicio, por ejemplo SSH. En la suplantación ARP (protocolo de resolución de direcciones), el atacante se hace pasar por el router y puede leer o modificar lo que iba hacia él. La denegación de servicio satura un dispositivo, por ejemplo con miles de solicitudes SYN que nunca se

completan: hay ida y casi no hay vuelta. Entre los ataques, unos pocos tipos concentran casi todos los casos y otros apenas aparecen (Sharmila & Nagapadma, 2023b).

En 2016, la *botnet* Mirai tomó miles de cámaras y grabadores con contraseñas de fábrica y lanzó una denegación de servicio contra Dyn; cayeron Twitter, Netflix y Amazon (Krebs, 2016). Un dispositivo atacado puede servir para dañar a otros, y hay que detectarlo a tiempo.

Los sistemas de detección de intrusos (IDS) vigilan el tráfico desde el router. Comparan con patrones conocidos o marcan lo que se aleja de lo normal. Con *machine learning*, el modelo aprende de registros de tráfico normal y de ataque, sin reglas escritas una a una, y clasifica un registro nuevo: cada etiqueta es una clase. Si unas clases tienen muchos registros y otras muy pocos, puede aprender la que más se repite y dejar sin marcar las que tienen pocos registros. Distintos modelos aprenden esa diferencia de distinta manera.

El tráfico une los tres temas: medio de los dispositivos IoT, canal de los ataques y fuente con la que el modelo aprende a detectarlos.

II. Estado del arte

La detección de intrusiones en redes IoT mediante aprendizaje automático se ha estudiado durante varios años, y buena parte de los trabajos ha seguido una ruta similar: comparar varios modelos clásicos y elegir el que obtiene mayor exactitud. Hasan et al. (2019), por ejemplo, buscaron predecir siete tipos de amenaza en sensores IoT, entre ellas la denegación de servicio, el escaneo y el espionaje, comparando regresión logística, máquinas de soporte vectorial, árboles de decisión, bosques aleatorios y redes neuronales; los tres últimos alcanzaron un 99,4 % de exactitud y el bosque aleatorio resultó el más consistente en las demás métricas. Con un objetivo parecido, Churcher et al. (2021) evaluaron siete clasificadores sobre el conjunto Bot-IoT, con y sin ponderar las clases según su tamaño. El bosque aleatorio destacó en la clasificación binaria y los K vecinos más cercanos en la multiclase, con un 99 % de exactitud; aun así, los propios autores advirtieron que algunos modelos confunden las clases con pocos registros, como la extracción de datos o el registro de pulsaciones de teclado, y que el desbalance podría distorsionar los resultados.

Esa advertencia se hace evidente cuando se mira más allá de la exactitud. Al presentar el conjunto CICIoT2023, Pinto Neto et al. (2023) probaron cinco modelos en tareas de 2, 8 y 34 clases: el bosque aleatorio mantuvo un 99,2 % de exactitud al distinguir 34 clases, pero su F1 bajó a 0,71, lo que muestra que un buen promedio global puede ocultar errores en los ataques menos comunes. Bulavas et al. (2021) abordaron este problema de forma directa: en lugar de agrupar o descartar las clases raras, como suele hacerse, las conservaron y generaron ejemplos sintéticos de ellas en tres conjuntos de tráfico de red, evaluando con métricas balanceadas. Concluyeron que los modelos basados en conjuntos de árboles, como el bosque aleatorio, ofrecieron el mejor desempeño en ese escenario.

Sobre RT-IoT2022, la literatura todavía es reducida. Sus autores, Sharmila y Nagapadma (2023a), lo construyeron a partir del tráfico de dispositivos IoT reales, como un asistente Amazon Alexa, una bombilla inteligente y un sensor de temperatura, y lo usaron para proponer un *autoencoder* cuantizado que separa el tráfico normal del anómalo y que reduce el tamaño del modelo en más de un 92 %, pensando en equipos de poca capacidad. Airlangga (2024) comparó *gradient boosting*, bosque aleatorio, regresión logística y un perceptrón multicapa, con resultados casi perfectos (1,00 de exactitud y de F1 en los dos primeros), pero sin detallar el desempeño en cada tipo de ataque. Prasad et al. (2025) propusieron eliminar registros redundantes de la clase mayoritaria antes de entrenar una red profunda, y reportaron un F1 de 0,9758 en RT-IoT2022, aunque en una tarea binaria. Por último, Ratnawati y Tedyyana (2026) ajustaron un modelo LightGBM con optimización por enjambre de partículas, tomando el macro-F1 como guía, y lo elevaron de 25,44 % a 97,10 %; no obstante, reconocen que su evaluación se limita a un solo conjunto de datos.

En conjunto, estos trabajos muestran que los modelos clásicos pueden detectar ataques en redes IoT con gran exactitud, pero varios se quedan en la exactitud global o en una tarea binaria, aunque algunos ya muestran que esa cifra no alcanza para los ataques con pocos registros. El presente trabajo complementa esa línea: en lugar de proponer un modelo nuevo o buscar el de mayor exactitud, compara cuatro modelos conocidos (K vecinos más cercanos, árbol de decisión, bosque aleatorio y red neuronal) sobre RT-IoT2022 y analiza, mediante el *recall* por tipo de ataque, el macro-F1 y la matriz de confusión, si ataques poco frecuentes como la fuerza bruta SSH o el escaneo FIN son realmente detectados y con qué otras clases se confunden.

III. Planteamiento del problema

A pesar de los avances en el uso de *machine learning* para la detección de intrusiones en dispositivos IoT, los modelos actuales enfrentan limitaciones relacionadas con el desbalance entre tipos de ataque. Cuando una clase domina los datos, los modelos tienden a sobreajustarse a ella y a dejar sin detectar los ataques con pocos registros, lo que eleva los falsos negativos (Shanmugam et al., 2025). En el conjunto RT-IoT2022, de 123 117 registros, un solo tipo de ataque, la denegación de servicio por solicitudes SYN, concentra 94 659, mientras que la fuerza bruta contra SSH y el escaneo FIN tienen apenas 37 y 28 registros, respectivamente (Sharmila & Nagapadma, 2023b). Aunque varios estudios reportan exactitudes superiores al 99 % en conjuntos de IoT con clases desbalanceadas, ese resultado puede ocultar un bajo desempeño en las clases escasas (Reddy & Kumar, 2026).

El efecto de este desbalance es medible: sobre RT-IoT2022, un modelo LightGBM sin optimizar alcanzó un 85,36 % de exactitud, pero solo un 25,44 % de macro-F1 (Ratnawati & Tedyyana, 2026). Es decir, un detector que parece preciso por su exactitud global puede estar ignorando los ataques con pocos registros, como la fuerza bruta contra

SSH y el escaneo FIN. En este contexto, la comparación de cuatro modelos de clasificación (K vecinos más cercanos, árbol de decisión, bosque aleatorio y red neuronal) se presenta como vía para determinar cuál reconoce los ataques que tienen pocos registros.

IV. Justificación

El problema es relevante porque ocurre en la red local de una casa, donde los dispositivos se actualizan poco y concentran las vulnerabilidades. El hogar promedio tiene 22 dispositivos conectados y recibe unos 29 ataques al día, frente a 10 en 2024. Entre enero y octubre de 2025 se registraron 13,6 mil millones de ataques en más de 6,1 millones de hogares (Bitdefender & NETGEAR, 2025). En esos hogares, los equipos de *streaming*, las *smart TV* y las cámaras IP reúnen más de la mitad de las vulnerabilidades detectadas, y las *smart TV* suelen conservarse entre cinco y ocho años, más allá del periodo en que el fabricante publica parches (Bitdefender & NETGEAR, 2025). El riesgo sale de la casa: el FBI advirtió que los ciberdelincuentes entran a redes domésticas por dispositivos IoT infectados de fábrica o durante la instalación, y los integran a la *botnet* BADBOX 2.0 y a servicios de *proxy* residencial; por eso recomendó vigilar el tráfico del hogar y revisar los dispositivos IoT (Federal Bureau of Investigation [FBI], 2025). El Instituto Nacional de Estándares y Tecnología (NIST) de Estados Unidos reconoce el IoT de consumo, el de uso doméstico o personal, como un sector con necesidades propias de ciberseguridad (Fagan et al., 2022). Este trabajo se dirige a tres dispositivos de esa red que RT-IoT2022 registra como tráfico normal: el LED de ThingSpeak, la bombilla Wipro y el sensor de temperatura por MQTT (Sharmila & Nagapadma, 2023b).

No resolver el desbalance entre tipos de ataque deja a esa casa sin aviso de lo escaso. La denegación de servicio por solicitudes SYN reúne 94 659 registros, la fuerza bruta contra SSH tiene 37 y el escaneo FIN tiene 28 (Sharmila & Nagapadma, 2023b): el primer ataque supera en más de 3 380 veces al tercero. Esos 65 registros son el 0,053 % de los 123 117, así que un modelo que nunca los marque pierde cerca de 0,05 puntos porcentuales de exactitud. En el hogar, más del 93 % de las interceptaciones de la defensa de red de Bitdefender en 2025 fueron escaneos de puertos (Bitdefender & NETGEAR, 2025). Esa exactitud alta, que en otros conjuntos de IoT ya esconde a las clases escasas, aquí escondería el escaneo FIN y la fuerza bruta contra SSH. A eso se suma que los terminales IoT tienen recursos limitados, escasez de datos etiquetados y desbalance de clases (Jiang et al., 2026), de modo que el detector de la casa tiene que reconocer también los ataques con pocos registros.

El beneficio es para quien tiene en casa el LED de ThingSpeak, la bombilla Wipro y el sensor de temperatura por MQTT. La comparación de K vecinos más cercanos, árbol de decisión, bosque aleatorio y red neuronal, con el *recall* de cada tipo, el macro-F1 y la matriz de confusión, permite ver si esos dos ataques quedan detectados.

V. Objetivos

Objetivo general

Comparar K vecinos más cercanos, árbol de decisión, bosque aleatorio y red neuronal en la detección de intrusiones sobre RT-IoT2022, para determinar cuál reconoce la fuerza bruta contra SSH y el escaneo FIN en la red doméstica del LED de ThingSpeak, la bombilla Wipro y el sensor de temperatura por MQTT, cuando la denegación de servicio por solicitudes SYN concentra la mayor parte de los registros.

Objetivos específicos

- Entrenar los cuatro modelos sobre las mismas clases de RT-IoT2022, sin agrupar la fuerza bruta contra SSH ni el escaneo FIN, para que la comparación refleje el desbalance entre tipos de ataque.
- Medir cada modelo con el *recall* de cada tipo, el macro-F1 y la matriz de confusión, para identificar cuál detecta los ataques con pocos registros y con qué clases los confunde.
- Contrastar esas medidas con la exactitud global, para mostrar si una exactitud alta deja sin detectar la fuerza bruta contra SSH y el escaneo FIN.

MARCO TEÓRICO

METODOLOGÍA

RESULTADOS

CONCLUSIONES

REFERENCIAS

Airlangga, G. (2024). Comparative analysis of machine learning models for intrusion detection in Internet of Things networks using the RT-IoT2022 dataset. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, *4*(2), 656–662. https://doi.org/10.57152/malcom.v4i2.1304

Bitdefender, & NETGEAR. (2025). *The 2025 IoT security landscape report*. https://blogapp.bitdefender.com/hotforsecurity/content/files/2025/10/2025_iot_security_report.pdf

Bulavas, V., Marcinkevičius, V., & Rumiński, J. (2021). Study of multi-class classification algorithms' performance on highly imbalanced network intrusion datasets. *Informatica*, *32*(3), 441–475. https://doi.org/10.15388/21-INFOR457

Chui, M., Collins, M., & Patel, M. (2021, 9 de noviembre). *IoT value set to accelerate through 2030: Where and how to capture it*. McKinsey & Company. https://www.mckinsey.com/capabilities/tech-and-ai/our-insights/iot-value-set-to-accelerate-through-2030-where-and-how-to-capture-it

Churcher, A., Ullah, R., Ahmad, J., Ur Rehman, S., Masood, F., Gogate, M., Alqahtani, F., Nour, B., & Buchanan, W. J. (2021). An experimental analysis of attack classification using machine learning in IoT networks. *Sensors*, *21*(2), Artículo 446. https://doi.org/10.3390/s21020446

Ericsson. (2026). *IoT connections outlook*. Ericsson Mobility Report, junio de 2026. https://www.ericsson.com/en/reports-and-papers/mobility-report/dataforecasts/iot-connections-outlook

Fagan, M., Megas, K. N., Watrobski, P., Marron, J., & Cuthill, B. (2022). *Profile of the IoT core baseline for consumer IoT products* (NIST IR 8425). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.IR.8425

Federal Bureau of Investigation. (2025, 5 de junio). *Home Internet connected devices facilitate criminal activity* (Alert No. I-060525-PSA). Internet Crime Complaint Center. https://www.ic3.gov/PSA/2025/PSA250605

Hasan, M., Islam, M. M., Zarif, M. I. I., & Hashem, M. M. A. (2019). Attack and anomaly detection in IoT sensors in IoT sites using machine learning approaches. *Internet of Things*, *7*, Artículo 100059. https://doi.org/10.1016/j.iot.2019.100059

Jiang, L., Zhao, Z., & Yang, H. (2026). A survey of machine learning intrusion detection methods for internet of things restricted terminals. *Journal of University of Electronic Science and Technology of China*, *55*(3), 411–425. https://doi.org/10.12178/1001-0548.2025226

Krebs, B. (2016, 21 de octubre). *Hacked cameras, DVRs powered today's massive Internet outage*. Krebs on Security. https://krebsonsecurity.com/2016/10/hacked-cameras-dvrs-powered-todays-massive-internet-outage/

OWASP Foundation. (2018). *OWASP Internet of Things Top 10 2018*. https://www.owasp.org/www-project-internet-of-things

Palo Alto Networks. (2020, 10 de marzo). *2020 Unit 42 IoT threat report*. https://unit42.paloaltonetworks.com/iot-threat-report-2020/

Pinto Neto, E. C., Dadkhah, S., Ferreira, R., Zohourian, A., Lu, R., & Ghorbani, A. A. (2023). CICIoT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment. *Sensors*, *23*(13), Artículo 5941. https://doi.org/10.3390/s23135941

Prasad, A., Alenazy, W. M., Ahmad, N., Ali, G., Abdallah, H. A., & Ahmad, S. (2025). Optimizing IoT intrusion detection with cosine similarity based dataset balancing and hybrid deep learning. *Scientific Reports*, *15*, Artículo 30939. https://doi.org/10.1038/s41598-025-15631-3

Ratnawati, F., & Tedyyana, A. (2026). Multiclass IoT intrusion detection based on particle swarm optimization-tuned light gradient boosting machine. *Journal of Embedded Systems, Security and Intelligent Systems*, *7*(2), 49–63. https://doi.org/10.59562/jessi.v7i1.2612

Reddy, D. S., & Kumar, K. A. (2026). A dataset-centric review of IoT and IIoT intrusion detection: Realism, evaluation biases, and future research directions. *Frontiers in Big Data*, *9*, Artículo 1878260. https://doi.org/10.3389/fdata.2026.1878260

Shanmugam, V., Razavi-Far, R., & Hallaji, E. (2025). Addressing class imbalance in intrusion detection: A comprehensive evaluation of machine learning approaches. *Electronics*, *14*(1), Artículo 69. https://doi.org/10.3390/electronics14010069

Sharmila, B. S., & Nagapadma, R. (2023a). Quantized autoencoder (QAE) intrusion detection system for anomaly detection in resource-constrained IoT devices using RT-IoT2022 dataset. *Cybersecurity*, *6*, Artículo 41. https://doi.org/10.1186/s42400-023-00178-5

Sharmila, B. S., & Nagapadma, R. (2023b). *RT-IoT2022* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5P338